LAB DE INTELIGENCIA ARTIFICIAL // ESPECIFICACIÓN TÉCNICA DE EVALUACIÓN [CORTE 2025]

PROYECTO IA: BRECHA DIGITAL Y RENDIMIENTO ESCOLAR EN EL PERÚ

Pipeline de Aprendizaje No Supervisado (Clustering), Clasificación Supervisada e IA Explicable (SHAP) sobre Microdatos ENAHO & ESCALE 2025

CURSO	ESCUELA PROFESIONAL	CORTE DE DATOS	MODALIDAD
Inteligencia Artificial	Ingeniería de Sistemas	ENAHO + ESCALE 2025	Evaluación Práctica / Informe

[01] CONTEXTO Y JUSTIFICACIÓN DEL PROBLEMA

El cierre de la brecha digital y su impacto real en la educación básica regular en el Perú (especialmente en zonas rurales y altoandinas) requiere ir más allá de la estadística descriptiva tradicional. En esta evaluación, los estudiantes actuarán como científicos de datos e investigadores en Inteligencia Artificial integrando dos fuentes oficiales de microdatos del Estado Peruano correspondientes al **año 2025**:

1. **ENAHO 2025 (INEI):** Encuesta Nacional de Hogares (condiciones socioeconómicas, equipamiento del hogar, lengua materna, uso de TICs y asistencia escolar).
2. **ESCALE 2025 (MINEDU):** Padrón y Censo Educativo (infraestructura escolar, coordenadas geográficas, ratio de alumnos por docente/computadora y conectividad a nivel distrital/escolar).

El propósito de este proyecto no es solo entrenar algoritmos por fuerza bruta, sino construir un pipeline reproducible, libre de **fuga de datos (data leakage)** en el entrenamiento y validación, que descubra patrones ocultos mediante **Clustering** y prediga estados de vulnerabilidad o brecha digital mediante **Clasificación / Regresión**, interpretando las decisiones con **SHAP**.

[02] OBJETIVOS Y ARQUITECTURA DEL PROYECTO

◈ Objetivo General

Desarrollar, validar e interpretar un pipeline integral de Machine Learning (No Supervisado y Supervisado) fusionando los microdatos de ENAHO 2025 y ESCALE 2025 para perfilar la brecha digital estudiantil y predecir el riesgo de rezago escolar o exclusión tecnológica en el Perú.

🔹 Objetivos Específicos

- **Ingeniería e Integración de Datos:** Ingestar microdatos crudos en formato `.csv` (y/o `.dbf` de ESCALE), conservando los ceros a la izquierda en las llaves primarias y geocódigos (`dtype=str`), realizar el cruce relacional a nivel de Hogar, Persona y Distrito (`UBIGEO`), y construir variables compuestas sin incurrir en fuga de datos (*data leakage*).
- **Aprendizaje No Supervisado (Clustering):** Descubrir perfiles o tipologías reales de estudiantes y distritos según su dotación tecnológica escolar y condiciones socioeconómicas del hogar (ej. K-Means, DBSCAN, Clustering Jerárquico o Gaussian Mixture Models).
- **Aprendizaje Supervisado (Clasificación y/o Pronóstico):** Entrenar y comparar algoritmos de ensamble y aprendizaje profundo tabular (LightGBM, XGBoost, CatBoost, Random Forest, MLP) aplicando validación cruzada agrupada (`GroupKFold` por conglomerado) para evitar la contaminación espacial entre entrenamiento y prueba.
- **Explicabilidad Algorítmica (XAI):** Auditar el mejor modelo utilizando valores **SHAP (SHapley Additive exPlanations)** para cuantificar el impacto de variables críticas como la lengua materna originaria (Quechua/Aimara), el estrato rural, la altitud y la infraestructura escolar.

[03] DATA HUB: ARQUITECTURA DE MICRODATOS 2025

1.

> **🛰️ REPOSITORIO OFICIAL DE DATOS DEL PROYECTO (GOOGLE DRIVE CLOUD)**
> Todos los archivos `.csv` de ENAHO 2025 y las bases de ESCALE 2025 requeridos para esta evaluación se encuentran disponibles para descarga directa en el siguiente enlace compartido: **Carpeta de Datos ENAHO - ESCALE 2025 (Google Drive)**.

⚙️ A. Microdatos INEI - ENAHO 2025 (Formato .csv)

Ruta de descarga: Portal de Microdatos del INEI → Consulta por Encuestas → ENAHO Metodología Actualizada → Año 2025 (Anual) → Formato CSV.

2.

MÓDULO	ARCHIVO ESPERADO	NIVEL	LLAVES DE UNIÓN	VARIABLES CLAVE
Módulo 01	`Enaho01-2025-100.csv`	Vivienda y Hogar	`AÑO, CONGLOM…`	`UBIGEO`, `DOMINIO`, `ESTRATO` (Urbano/Rural), acceso a alumbrado eléctrico (`P1121`), conexión a Internet en el hogar (`P1144`).
Módulo 02	`Enaho01-2025-200.csv`	Miembros del Hogar	`AÑO, CONGLOM…`	Sexo (`P207`), Edad en años cumplidos (`P208A`, filtrar edad escolar: 6 a 17 años), parentesco (`P203`).

MÓDULO	ARCHIVO ESPERADO	NIVEL	LLAVES DE UNIÓN	VARIABLES CLAVE
Módulo 03	`Enaho01a-2025-300.csv`	Educación y TICs	`AÑO, CONGLOM…`	Lengua materna (`P300A`), matriculación y asistencia escolar (`P306`, `P307`), nivel/grado (`P308A`, `P308B`), uso de Internet (`P314A`), lugar y frecuencia de uso de TICs (`P314B`, `P316`), habilidades digitales.
Módulo 34	`Sumaria-2025.csv`	Sumaria del Hogar	`AÑO, CONGLOM…`	Condición de pobreza (`POBREZA`: pobre extremo, no extremo, no pobre), gasto e ingreso neto (`GASHOG2D`, `INGHOG2D`), factor de expansión (`FACTOR07`).

⚙️ B. Microdatos MINEDU - ESCALE 2025 (Formato .dbf)

Ruta de descarga: Portal ESCALE MINEDU → Archivo de Datos → Censo Educativo 2025 / Padrón de Instituciones Educativas.

3.

ARCHIVO	NIVEL DE REGISTRO	LLAVE GEOGRÁFICA / ESCOLAR	VARIABLES CLAVE
`00 Padron.zip` / **`Padron_web.dbf`**	Institución Educativa (`COD_MOD`)	`CODGEO` (equivale al `UBIGEO` de 6 dígitos)	Nivel educativo (`NIV_MOD`), gestión pública/privada (`GESTION`), área censal (`DAREACENSO`), total de alumnos (`TALUMNO`), total de docentes (`TDOCENTE`), total de secciones (`TSECCION`).
`00 Padlocal.zip`	Local Escolar (`CODLOCAL`)	`UBIGEO` / `CODLOCAL`	Coordenadas geográficas (`NLAT_IE`, `NLONG_IE`), altitud aproximada e indicadores de infraestructura del local escolar.

[04] PIPELINE DE INGENIERÍA Y MODELADO IA

🧬 Fase 1: Preprocesamiento, Cruce Relacional y Prevención de Fuga de Datos (Data Leakage)

4. **Lectura de Microdatos y Cuidado de Tipos en CSV:** Cargar los archivos `.csv` de ENAHO directamente considerando las siguientes consideraciones técnicas críticas:

5.

> ⚠️ **ALERTA DE INGESTA: 3 TRAMPAS CRÍTICAS EN MICRODATOS CSV DEL INEI**
>
> **Trampa 1 — Pérdida de ceros a la izquierda en las llaves (`UBIGEO`, `CONGLOME`, `VIVIENDA`, `HOGAR`, `CODPERSO`):** Si se ejecuta un `pd.read_csv()` simple, Pandas convierte códigos como `'010101'` (Chachapoyas) en el entero `10101`, o `'01'` en `1`, provocando que el cruce relacional (`merge`) falle o pierda regiones enteras. Se debe forzar `dtype=str` en todas las llaves.
>
> **Trampa 2 — Espacios en blanco (`' '`) como valores nulos:** En los archivos `.csv` del INEI, cuando una pregunta presenta un salto lógico o no aplica, la celda no viene vacía (`""`), sino con uno o más espacios en blanco (`" "`), convirtiendo columnas numéricas en tipo `object` (`string`). Se resuelve pasando `na_values=[' ', '  ', '   ', '']`.
>
> **Trampa 3 — Codificación `latin1` (`ISO-8859-1`):** Los encabezados de los archivos del INEI incluyen caracteres especiales como la letra `Ñ` en la columna `AÑO`. Intentar leerlos con el estándar `utf-8` por defecto arroja un error `UnicodeDecodeError`.

6.

💻 TERMINAL PYTHON 3.12 // INGESTA SEGURA DE MICRODATOS INEI (.CSV)

```python
import pandas as pd

# 1. Definir llaves compuestas como string para NO perder ceros a la izquierda
llaves_str = {
    'AÑO': str,
    'MES': str,
    'CONGLOME': str,
    'VIVIENDA': str,
    'HOGAR': str,
    'CODPERSO': str,
    'UBIGEO': str
}

def cargar_csv_inei(ruta_csv, usecols=None):
    """
    Lee archivos CSV de microdatos del INEI manejando codificación latin1,
    espacios en blanco como NaN y preservando ceros en llaves primarias.
    """
    df = pd.read_csv(
        ruta_csv,
        encoding='latin1',
        dtype=llaves_str,
        na_values=[' ', '  ', '   ', ''],
        usecols=usecols,
        low_memory=False
    )
    # Estandarizar nombres de columnas a mayúsculas por seguridad
```

```
    df.columns = df.columns.str.upper().str.strip()
    return df

# Ejemplo de carga rápida del Módulo 300 (Educación) y Sumaria 2025:
# df_edu = cargar_csv_inei("data/raw/inei_enaho/Enaho01a-2025-300.csv")
# df_sum = cargar_csv_inei("data/raw/inei_enaho/Sumaria-2025.csv")
```

7. **Filtrado de Población Objetivo:** Seleccionar en el Módulo 200 y 300 a la población en edad escolar (6 a 17 años).
8. **Agregación Contextual de ESCALE:** Agrupar los datos de `Padron_web.dbf` por distrito (`CODGEO` = `UBIGEO`) y área (Urbana/Rural) para calcular:
    - Ratio distrital de alumnos por docente (`TALUMNO / TDOCENTE`).
    - Proporción de colegios públicos vs. privados en el distrito.
    - Coordenadas medias del distrito (`NLAT_IE`, `NLONG_IE`).
9. **Cruce Maestro (Merge):** Unir `Módulo 300` + `Módulo 200` + `Módulo 100` + `Sumaria` + `Indicadores Distritales ESCALE`.

1.

> 🛡️ **PROTOCOLO ESTRICTO ANTI-FUGA DE DATOS (ZERO DATA LEAKAGE EN ML)**
>
> **Regla 1 (Partición por Conglomerado):** Los miembros de un mismo hogar o vecindario (`CONGLOME`) comparten características idénticas. Está **terminantemente prohibido** usar un `train_test_split` aleatorio simple. Toda partición de entrenamiento y prueba debe hacerse agrupando por `CONGLOME` (`GroupShuffleSplit` o `GroupKFold`).
>
> **Regla 2 (Transformaciones dentro del Fold):** La imputación de valores nulos, el escalado (`StandardScaler` / `RobustScaler`) y la codificación de variables categóricas deben ajustarse (`fit`) **únicamente en el conjunto de entrenamiento (X_train)** y aplicarse (`transform`) al conjunto de prueba (`X_test`).
>
> **Regla 3 (Exclusión de Variables Proxy Directas):** Si se predice pobreza o atraso escolar, no incluir variables que contengan explícitamente la respuesta (como el cálculo directo de la línea de pobreza o el resultado final del año escolar posterior).

🧠 Fase 2: Modelado No Supervisado (Clustering y Perfilamiento)

2. **Selección de Variables Continuas y Socio-Tecnológicas:** Ingreso/gasto per cápita del hogar, ratio alumnos/docente de su distrito, frecuencia de uso de TICs, años de retraso escolar y acceso a servicios básicos.
3. **Reducción de Dimensionalidad:** Aplicar **PCA** o **UMAP** para visualización en 2D/3D.
4. **Experimentación con Algoritmos de Clustering:**
    - Implementar y comparar al menos dos métodos: **K-Means / K-Prototypes** (para datos mixtos) y **Clustering Jerárquico Aglomerativo** o **GMM (Gaussian Mixture Models)**.

    - Determinar el número óptimo de clusters (k) justificando con métricas cuantitativas: **Coeficiente de Silueta (Silhouette Score)**, **Índice Davies-Bouldin** e **Índice Calinski-Harabasz**.
5. **Interpretación de Clusters:** Bautizar cada cluster encontrado (ej. *Cluster 1: "Rural Altoandino con Aislamiento Digital pero Alta Asistencia"*, *Cluster 2: "Urbano Vulnerable con Acceso Móvil Limitado"*, etc.).

🎯 Fase 3: Modelado Supervisado (Clasificación y/o Pronóstico)

Los equipos deberán formular y resolver **al menos uno** de los siguientes problemas predictivos:

- **Opción A (Clasificación Binaria o Multiclase):** Predecir el **Rezago / Atraso Escolar** (cuando la edad del estudiante supera la edad normativa para su grado escolar actual) o la **Exclusión Digital Efectiva** (estudiantes que a pesar de asistir al colegio no logran desarrollar competencias digitales ni uso de internet).
- **Opción B (Pronóstico / Regresión):** Estimar un **Índice Continuo de Brecha Educativa-Digital** o predecir la tasa de retención/aprobación distrital integrando las variables del hogar y de ESCALE.

Requisitos del Entrenamiento Supervisado:

- Entrenar una línea base (*Baseline*: Regresión Logística / Árbol de Decisión simple) frente a al menos **tres modelos avanzados** (`LightGBM`, `XGBoost`, `CatBoost`, `Random Forest` o `MLP / TabNet` en PyTorch).
- Manejar el desbalance de clases (si existe) mediante pesos en la función de pérdida (`class_weight` o `scale_pos_weight`) y considerar el factor de expansión muestral (`FACTOR07`).
- Evaluar el rendimiento en el conjunto de prueba (aislado por `CONGLOME`) reportando: **ROC-AUC**, **PR-AUC (Precision-Recall AUC)**, **F1-Score Macro**, **Matriz de Confusión** y **Curva de Calibración**.

🔍 Fase 4: Inteligencia Artificial Explicable (XAI)

1. Generar el gráfico global **SHAP Summary Plot (Beeswarm)** para identificar las 10 variables más determinantes del modelo ganador.
2. Generar al menos dos gráficos **SHAP Dependence Plot** para analizar interacciones no lineales (por ejemplo: cómo interactúa la lengua materna Quechua/Aimara con la disponibilidad de internet en el hogar o el ratio alumno/docente del distrito).
3. Explicar dos casos individuales extremos mediante **SHAP Waterfall Plot** (un estudiante correctamente clasificado en alto riesgo y otro de bajo riesgo).

[05] ENTREGABLES Y ESPECIFICACIÓN DE PRODUCTOS

Cada equipo o estudiante deberá presentar los siguientes productos:

1. **Repositorio de Código Reproducible (GitHub / Carpeta estructurada):**
    - Estructura limpia (`data/raw`, `data/processed`, `notebooks/`, `src/`).

- Notebooks de Jupyter (`.ipynb`) o scripts en Python (`.py`) completamente ejecutables, documentados y con semilla aleatoria fija (`random_state=42`) para garantizar la reproducibilidad.

2. **Dataset Procesado (`dataset_enaho_escale_2025.parquet` o `.csv`):**
   - Tabla limpia producto de la fusión de los módulos 100, 200, 300, Sumaria y ESCALE 2025, acompañada de su diccionario de variables creadas.
3. **Informe Técnico en Formato Artículo Científico (4 a 6 páginas, estilo IEEE / MDPI):**
   - **Resumen (Abstract)** e **Introducción**.
   - **Metodología de Datos:** Diagrama del cruce de tablas, tratamiento de valores perdidos y demostración explícita de cómo se evitó el *data leakage*.
   - **Resultados de Clustering:** Gráficos de silueta, proyección UMAP/PCA y tabla de caracterización de cada perfil estudiantil.
   - **Resultados de Clasificación/Pronóstico:** Tabla comparativa de modelos con validación cruzada `GroupKFold`, curvas ROC/PR y análisis crítico de errores (Falsos Positivos vs. Falsos Negativos).
   - **Análisis de Explicabilidad (SHAP) y Conclusiones:** Recomendaciones de política educativa basadas en la evidencia matemática obtenida.

[06] MATRIZ DE EVALUACIÓN Y RÚBRICA (20 PTS)

CRITERIO DE EVALUACIÓN	DESCRIPCIÓN DE LO ESPERADO	PUNTAJE
1. Ingeniería de Datos y Cero Fuga de Datos (Data Leakage)	Cruce correcto por llaves compuestas (`CONGLOME`, `VIVIENDA`, `HOGAR`, `CODPERSO`, `UBIGEO`). Separación estricta por grupos (`GroupKFold`) y transformaciones ajustadas solo en `train`.	5 pts
2. Calidad del Clustering (No Supervisado)	Escalamiento adecuado, justificación matemática del número de clusters (Silueta, Davies-Bouldin) e interpretación socioeducativa coherente de los perfiles hallados.	4 pts
3. Rigor en Clasificación / Pronóstico (Supervisado)	Comparación justa de múltiples arquitecturas, ajuste de hiperparámetros, manejo del desbalance de clases y reporte de métricas apropiadas (ROC-AUC, PR-AUC, F1).	5 pts
4. Interpretabilidad con XAI (SHAP)	Aplicación e interpretación profunda de gráficos SHAP globales (Beeswarm), de interacción (Dependence) y locales (Waterfall).	3 pts
5. Redacción Científica, Código Limpio y Defensa	Orden del repositorio, claridad de las visualizaciones, formato tipo paper y dominio técnico durante la sustentación oral del código.	3 pts
TOTAL	Puntaje máximo de la evaluación práctica	20 pts