Brecha digital y rezago escolar en el Perú: integración ENAHO-ESCALE 2025 con aprendizaje automático explicable

Unidad de Inteligencia Artificial | Escuela Profesional de Ingeniería de Sistemas | Octubre de 2026

RESUMEN

Se desarrolló un pipeline reproducible para caracterizar la brecha digital y predecir rezago escolar en estudiantes peruanos de 6 a 17 años. Se fusionaron ENAHO 2025 y ESCALE a nivel de persona, hogar y distrito. El dataset final contiene **23,668 estudiantes**; 9,382 fueron evaluables y 520 presentaron rezago (5.54%). La validación agrupada por conglomerado evitó contaminación territorial. K-Means identificó dos perfiles; CatBoost obtuvo el mayor PR-AUC medio en GroupKFold (0.0937). SHAP destacó dominio geográfico, oferta escolar, tableta, ratio alumno/docente y recursos económicos. Los resultados son predictivos y asociativos, no causales.

Palabras clave: ENAHO, ESCALE, rezago escolar, brecha digital, GroupKFold, CatBoost, SHAP.

I. INTRODUCCIÓN Y CONTRIBUCIÓN

La desigualdad educativa combina restricciones del hogar, acceso tecnológico y heterogeneidad territorial. La guía del proyecto exige integrar fuentes oficiales, descubrir perfiles, comparar clasificadores y auditar decisiones [1]. La estructura muestral ENAHO usa conglomerados como unidades primarias [2]; por ello una partición aleatoria simple inflaría el rendimiento. Este trabajo aporta una integración trazable, un protocolo de cero fuga, comparación de seis modelos y explicaciones globales e individuales.



II. DATOS, TARGET Y PROTOCOLO ANTI-FUGA

Se integraron M100, M200, M300 y Sumaria de ENAHO con el Padrón de Instituciones y Locales ESCALE. Todas las llaves se preservaron como texto y los UBIGEO se normalizaron a seis dígitos. La población se restringió después del cruce a edades de 6 a 17 años.

Indicador	Valor
Estudiantes 6-17	23,668
Distritos	1,240
Conglomerados	5,050
Evaluables para rezago	9,382
Rezago positivo	520 (5.54%)
Exclusión digital	332 (1.40%)

Definición y controles

El target se definió como **1[edad > edad normativa(nivel, grado) + 1]** para estudiantes matriculados o asistentes en primaria/secundaria. Se excluyeron edad, nivel, grado, edad normativa y población evaluable de los predictores. La partición externa fue GroupShuffleSplit 80/20; la validación interna, GroupKFold(5). Imputación, RobustScaler y one-hot se ajustaron dentro de cada fold. Los 3,243 conglomerados de train y 811 de test tuvieron solapamiento cero.

Riesgo	Control implementado
Pérdida de ceros	dtype string + zfill(6)
Duplicidad relacional	validate one_to_one / many_to_one
Contaminación espacial	Split y CV por CONGLOME
Fuga del target	Exclusión de componentes directos
Desbalance	Pesos de clase + factor07 normalizado

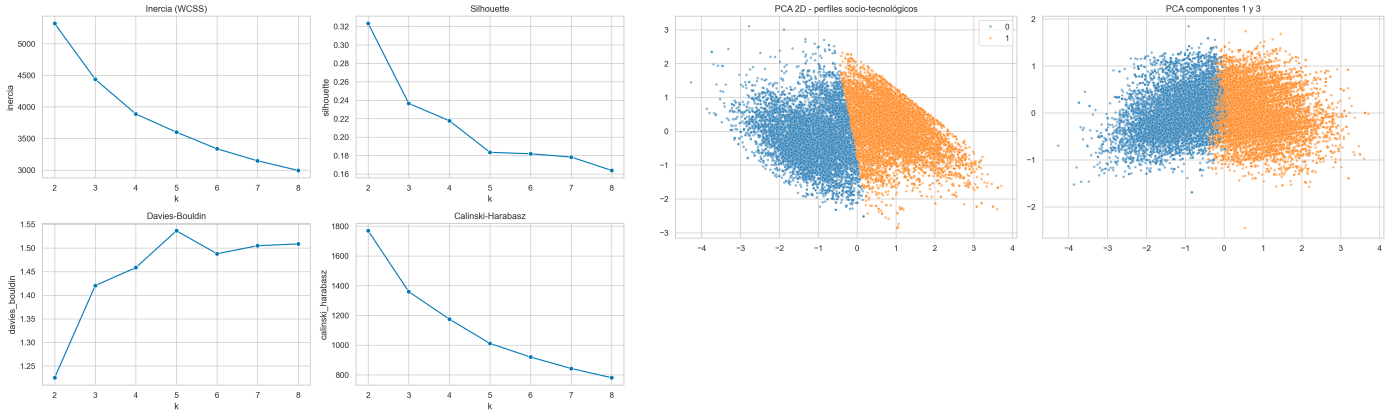
Variables de modelado

Hogar: gasto, ingreso, electricidad, computadora, laptop, tableta e internet. **Persona:** sexo, lengua, uso reciente de internet y equipamiento. **ESCALE:** ratio alumno/docente, locales, gestión pública y ruralidad. Las transformaciones logarítmicas se aplicaron a gasto e ingreso per cápita.

III. RESULTADOS NO SUPERVISADOS

K-Means y Gaussian Mixture se compararon sobre diez variables sin incluir el target. El balance de Silhouette, Davies-Bouldin y Calinski-Harabasz seleccionó k=2. Las tres primeras componentes PCA explicaron 81.21% de la varianza.

k	Silhouette	Davies-Bouldin	Calinski-Harabasz
2	0.3233	1.2251	1769.0
3	0.2364	1.4203	1359.2
4	0.2177	1.4583	1174.5



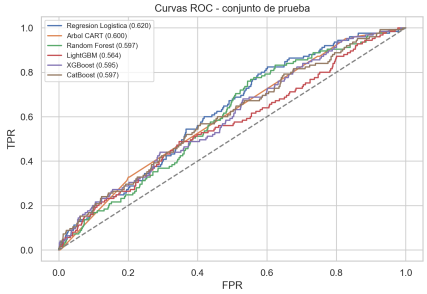
Perfil	n	Internet	Uso internet	Rezago	Exclusión digital
Rural vulnerable con aislamiento digital y dependencia pública	10,239	91.5%	58.7%	6.19%	3.14%
Urbano consolidado con alta conectividad y mejores recursos	13,429	98.0%	83.2%	5.07%	0.08%

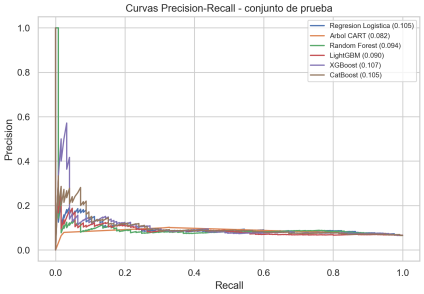
El perfil rural vulnerable presenta menor conectividad y una tasa de exclusión digital casi 38 veces mayor. La tasa de rezago supera en 1.12 puntos porcentuales a la del perfil urbano. El target se utilizó solo después del ajuste para caracterización externa.

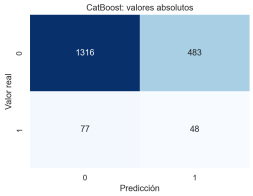
IV. CLASIFICACIÓN SUPERVISADA

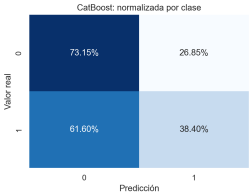
El criterio de selección fue PR-AUC media en GroupKFold, apropiado para una prevalencia de 5.54%. CatBoost fue el campeón de validación; XGBoost obtuvo el mayor PR-AUC puntual en test y la regresión logística el mayor recall.

Modelo	PR-AUC CV	ROC test	PR test	F1 macro	Recall	Brier
CatBoost	0.0937	0.5969	0.1048	0.4855	0.384	0.1803
Random Forest	0.0912	0.5973	0.0939	0.5170	0.056	0.0941
XGBoost	0.0887	0.5951	0.1068	0.4904	0.320	0.1677
Regresion Logistica	0.0846	0.6196	0.1055	0.4046	0.672	0.2595
LightGBM	0.0844	0.5637	0.0902	0.5247	0.216	0.1280
Arbol CART	0.0656	0.6001	0.0820	0.5092	0.328	0.2377







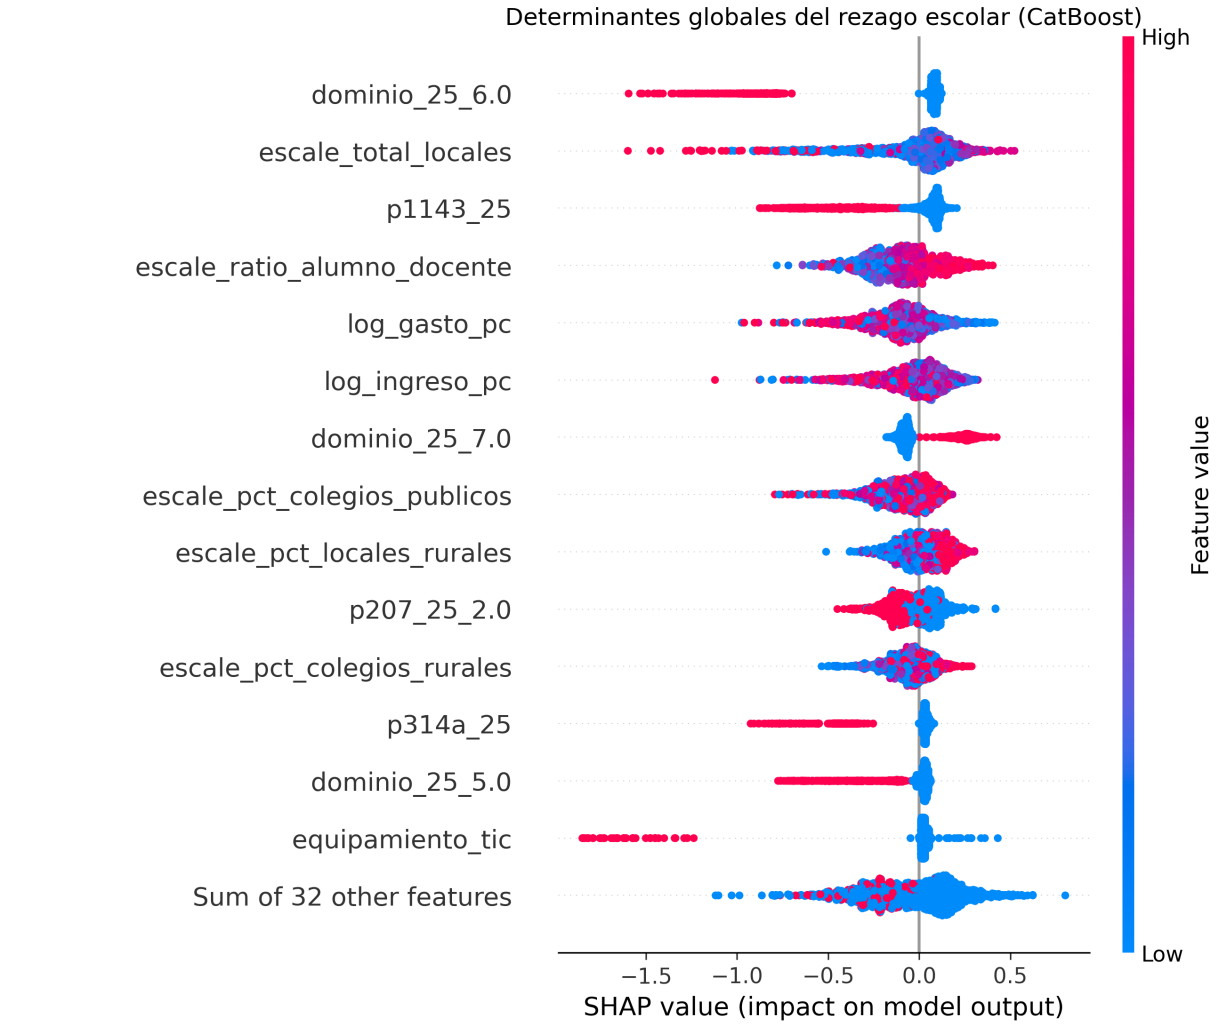


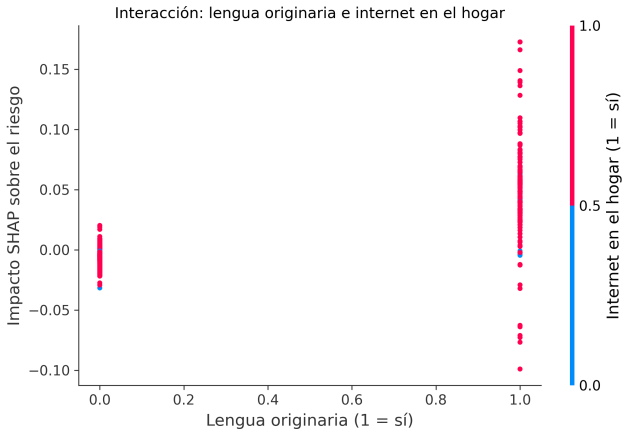
Análisis de errores

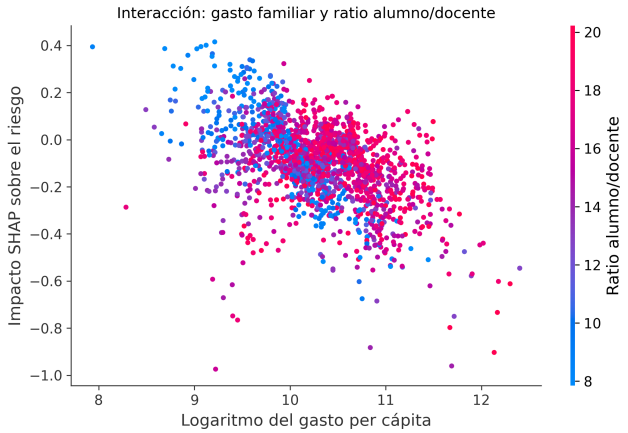
CatBoost produjo 1,316 verdaderos negativos, 483 falsos positivos, 77 falsos negativos y 48 verdaderos positivos. El balanceo mejora detección, pero reduce precisión y distorsiona probabilidades. El desempeño es moderado: el modelo sirve para priorización exploratoria, no para decisiones automáticas. Se requiere calibración antes de un uso operativo.

V. EXPLICABILIDAD ALGORÍTMICA CON SHAP

TreeExplainer auditó CatBoost sobre 1,924 casos de prueba. Los valores SHAP están en log-odds: valores positivos elevan la salida de riesgo y negativos la reducen.

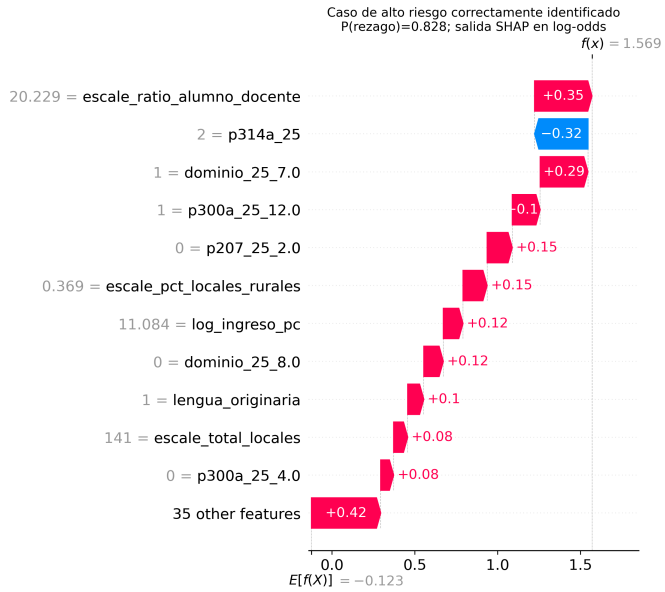


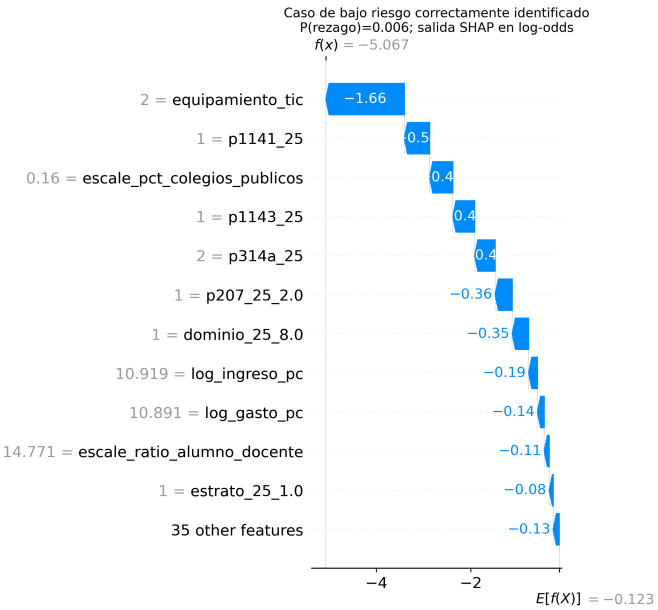




Dominio geográfico, oferta de locales, tableta, ratio alumno/docente y recursos económicos encabezan la importancia. La relación gasto-riesgo es no lineal; la señal lengua-internet es débil y no permite afirmar un efecto multiplicador fuerte. SHAP explica asociaciones internas del modelo, no causalidad.

VI. AUDITORÍA INDIVIDUAL, RECOMENDACIONES Y CONCLUSIONES





El caso positivo extremo alcanzó P(rezago)=0.828; el alto ratio alumno/docente, dominio territorial, lengua originaria y ruralidad aumentaron el riesgo. El caso negativo extremo obtuvo 0.006; equipamiento TIC, computadora, tableta y mejores recursos económicos actuaron como factores protectores dentro del modelo.

Recomendaciones de política

1) Priorizar acompañamiento en conglomerados rurales vulnerables. 2) Vincular entrega de dispositivos con uso efectivo, electricidad y soporte. 3) Monitorear distritos con ratios alumno/docente altos. 4) Usar el modelo como apoyo humano y auditable, nunca como decisión automática sobre estudiantes.

Limitaciones

El corte es transversal; la clase positiva es escasa; ESCALE se agregó por distrito; y el rendimiento predictivo es moderado. Se requieren calibración, validación temporal/geográfica y auditorías de equidad por sexo, lengua y territorio.

Referencias

[1] Lab de IA, Guía de Evaluación: Brecha Digital y Educación 2025. [2] INEI, Ficha Técnica Panel ENAHO 2021-2025. [3] MINEDU, RM 064-2022-MINEDU. [4] INEI, Cuestionarios ENAHO M100 y M300, 2025. [5] MINEDU-ESCALE, Diccionario del Censo Educativo 2025. [6] Lundberg y Lee, A Unified Approach to Interpreting Model Predictions, NeurIPS, 2017. [7] Prokhorenkova et al., CatBoost, NeurIPS, 2018.